

E-Ticaret Yorumlarında Konu Bazlı Duygu Analizi: Kural Tabanlı, Hibrit ve Transformer Yaklaşımlarının Karşılaştırmalı İncelemesi

Ahmet Çağlar
Software Engineering
Kocaeli University
Kocaeli, Turkey
230229080@kocaeli.edu.tr

Dilara Çatalçam
Software Engineering
Kocaeli University
Kocaeli, Turkey
210229056@kocaeli.edu.tr

İbrahim Biner
Software Engineering
Kocaeli University
Kocaeli, Turkey
220229049@kocaeli.edu.tr

Özet—Bu çalışmada, Trendyol e-ticaret platformundaki elektronik ürün yorumları üzerinde Konu Bazlı Duygu Analizi (Aspect-Based Sentiment Analysis, ABSA) problemi ele alınmıştır. Geleneksel duygu analizi bir yorumu bütün olarak tek bir kutba indirirken, gerçek yorumlar çoğu zaman farklı boyutlara yönelik birbirinden bağımsız duygular içerir. Çalışmada üç farklı elektronik kategorisinden toplanan 2.250 ham yorum etiketlenerek 3.358 adet konu-duygu çifti elde edilmiştir. Aynı veri seti üzerinde dört yaklaşım (kural tabanlı sözlük yöntemi, TF-IDF tabanlı hibrit makine öğrenmesi, BERTürk ve KOZMOS ince ayar modelleri) karşılaştırılmıştır. Veri sızıntısını önlemek için yorum bazlı gruplandırılmış bölme uygulanmış ve test-eğitim örtüşmesi %0'a indirilmiştir. Ana başarı ölçütü olarak makro F1 kullanılmıştır. En yüksek başarıyı 0.69 makro F1 ve %81.4 doğruluk ile BERTürk modeli elde etmiştir. KOZMOS modeli 0.657 makro F1 ile yakın bir performans göstermiştir. Tüm modeller için en zorlayıcı sınıf, hem örnek azlığı hem de etiketleme öznelliği nedeniyle nötr sınıfı olmuştur.

Anahtar Kelimeler—konu bazlı duygu analizi, ABSA, doğal dil işleme, BERTürk, transformer, TF-IDF, metin madenciliği, e-ticaret.

Abstract—This study addresses the Aspect-Based Sentiment Analysis (ABSA) problem on electronic product reviews from the Trendyol e-commerce platform. While traditional sentiment analysis reduces a review to a single polarity, real reviews often contain independent sentiments toward different aspects. A total of 2,250 raw reviews from three electronic categories were labeled, yielding 3,358 aspect-sentiment pairs. Four approaches (rule-based lexicon, TF-IDF hybrid machine learning, BERTürk and KOZMOS fine-tuned models) were compared on the same dataset. Group-based splitting was applied to prevent data leakage, reducing train-test overlap to 0%. Using macro F1 as the primary metric, BERTürk achieved the highest performance with 0.69 macro F1 and 81.4% accuracy. The KOZMOS model followed closely with 0.657 macro F1. The neutral class remained the most challenging for all models due to both sample scarcity and labeling subjectivity.

Keywords—aspect-based sentiment analysis, ABSA, natural language processing, BERTürk, transformer, TF-IDF, text mining, e-commerce.

I. GİRİŞ VE PROBLEM TANIMI

E-ticaret platformlarında biriken kullanıcı yorumları, tek bir yıldız puanıyla özetlenemeyecek kadar zengin bilgi taşır. Bir kullanıcı ürünün kalitesinden memnun olurken kargo hizmetinden şikâyetçi olabilir, ya da bataryayı beğenirken fiyatı pahalı bulabilir. Yorumu bütünsel olarak tek bir olumlu/olumsuz etikete indirgeyen geleneksel duygu analizi yöntemleri, ürünün hangi yönünün beğenildiği veya eleştirildiği ayrımını yakalayamaz. Bu durum hem tüketicinin karar verme sürecini hem de satıcının ürün geliştirme geri bildirimini bilgi kaybına uğrattır.

Bu projenin amacı, ürün yorumlarını boyutlarına ayırarak her boyut için ayrı bir duygu sınıflandırması yapan bir Konu Bazlı Duygu Analizi (ABSA) sistemi geliştirmektir. Örneğin “Kamerası harika ama batarya bir günü zor götürüyor, kargo hızlıydı” yorumunda sistem; ses/görüntü boyutunu pozitif, batarya boyutunu negatif ve kargo boyutunu pozitif olarak etiketlemelidir.

Araştırma sorusu: Türkçe e-ticaret yorumlarında konu bazlı duygu sınıflandırması için kural tabanlı, klasik makine öğrenmesi ve transformer tabanlı dil modelleri arasında başarı, maliyet ve yorumlanabilirlik açısından nasıl bir denge oluşmaktadır? Bu denge, özellikle dengesiz sınıf dağılımı altında nasıl değişmektedir?

Bu probleme cevap verebilmek için veri madenciliği yaşam döngüsünün tüm aşamaları uçtan uca uygulanmış ve aynı veri seti üzerinde dört farklı yaklaşım karşılaştırılmıştır.

II. İLGİLİ ÇALIŞMALAR

ABSA, SemEval-2014 Task 4 ile literatürde standart bir alt görev hâline gelmiştir [1]. Erken dönem çözümler sözlük ve kural tabanlı iken, derin öğrenmenin yaygınlaşmasıyla bağlamı modelleyen yaklaşımlar öne çıkmıştır. BERT mimarisi [2], maskelenmiş dil modeli ön eğitimi sayesinde birçok doğal dil işleme görevinde fine-tuning ile güçlü sonuçlar vermiştir. Sun ve ark. [3], ABSA problemini bir cümle çifti sınıflandırma

TABLE I
KATEGORİ BAZINDA ETİKETLİ KONU-DUYGU ÇİFTİ SAYILARI

Kategori	Etiketli Çift
Telefon	1.056
Kulaklık	1.159
Bilgisayar	1.143
Toplam	3.358

görevine dönüştüren yardımcı cümle (auxiliary sentence) yaklaşımını önermiş; “{yorum} [SEP] {aspect}” biçiminde girdi kurularak modelin ilgili boyuta odaklanması sağlanmıştır. Bu çalışmada da transformer modelleri aynı yardımcı cümle formatıyla eğitilmiştir. Türkçe için, dbmdz tarafından yayımlanan BERTürk [4] ve Yıldız Teknik Üniversitesi tarafından geliştirilen KOZMOS Türkçe BERT modeli [5] kullanılmıştır.

III. VERİ TOPLAMA

Veri seti, Trendyol platformundan üç elektronik kategorisi (telefon, kulaklık, bilgisayar) seçilerek Python ve Selenium tabanlı bir web scraping aracıyla toplanmıştır. Toplam altı farklı ürün (iPhone 13, iPhone 11, Samsung Galaxy A24; AirPods 2, AirPods 4, Redmi Buds 6 Play; MacBook Air M1, Lenovo IdeaPad, Casper) hedeflenmiş ve toplamda 2.250 ham yorum elde edilmiştir.

Kazıma sürecinde teknik sorunlarla karşılaşmış ve çözülmüştür. Bu sorunlardan birincisi şudur: Trendyol’un genel yorum API’si Cloudflare ile korunduğundan doğrudan istekler 403 hatası döndürmüştür. Çözüm olarak gerçek bir Chrome tarayıcısını süren Selenium tabanlı kazıma kullanılmıştır. İkinci sorun; Trendyol’un yorum bölümünde infinite scroll JavaScript ile çalıştığından, headless Chrome modu sayfayı tam yükleyememektedir. Bu nedenle tarayıcı görünür modda çalıştırılmıştır. Bir diğer sorun ise, platformun varsayılan yorum sıralaması ağırlıklı olarak 5 yıldızlı yorumları öne çıkarmakta ve bu durum sınıf dengesizliğini artırmaktadır. Daha dengeli bir dağılım için yıldız parametresi üzerinden 1 ile 5 yıldız arasındaki bütün yıldızlardan eşit şekilde ürün yorumları alınarak filtreleme yapılarak olumsuz ve nötr yorumların da kazanması sağlanmıştır.

Etik not: Toplanan yorumlar herkese açık ürün sayfalarından alınmıştır; veride kişisel kimlik bilgisi bulundurulmamış, yalnızca yorum metni, boyut ve duygu etiketi saklanmıştır.

IV. VERİ ANLAMA VE KEŞİFSEL ANALİZ

Etiketleme sonucunda 2.250 ham yorumdan 3.358 adet konu-duygu çifti üretilmiştir. Tek bir yorum birden fazla boyutla ilgili olabileceğinden birden çok satır oluşturmaktadır. Kategori bazında etiketli çift sayıları Tablo I’de verilmiştir.

Veri yedi boyut etrafında düzenlenmiştir: genel, kargo, kalite, fiyat, batarya, ses/görüntü ve ambalaj. Boyut dağılımı Şekil 1’de görülmektedir. “Genel” boyutu, ürüne dair bütünsel değerlendirmeleri içerdiği için açık ara en sık görülen sınıftır. Kargo, kalite ve ses/görüntü orta sıklıkta; batarya, fiyat ve ambalaj ise görece seyrek boyutlardır.




Fig. 1. Boyut (aspect) frekans dağılımı.

TABLE II
KÜME BAZINDA DUYGU (SENTIMENT) SINIF DAĞILIMI

Sınıf	Eğitim	Doğrulama	Test
Pozitif	1.336	284	305
Negatif	822	175	160
Nötr	184	47	45
Toplam	2.342	506	510




Fig. 2. Boyut × duygu çapraz dağılımı.

Duygu ekseninde ise belirgin bir dengesizlik vardır: yorumların yaklaşık %59’u pozitif, %32’si negatif ve yalnızca %9’u nötrdür. Bu dengesizlik, üç kümedeki sınıf sayılarıyla birlikte Tablo II’de verilmiştir. Boyut ve duygu eksenlerinin birlikte dağılımı Şekil 2’de gösterilmiştir; bu çapraz dağılım, nötr sınıfının her boyutta ne kadar seyrek kaldığını ve modellemeye neden en zorlayıcı sınıf olacağını önceden işaret etmektedir.

Yorum uzunluğu dağılımı (Şekil 3) incelendiğinde, yorumların büyük çoğunluğunun kısa-orta uzunlukta olduğu, bir kuyruk oluşturan uzun yorumların ise birden fazla boyutu aynı anda barındırdığı görülmüştür. Bu gözlem, transformer modelleri için 128 tokenlık maksimum uzunluğun yorumların ezici çoğunluğunu kayıpsız kapsadığını doğrulamıştır.

Son olarak, ham veri üzerinden oluşturulan kelime bulutu (WordCloud) Şekil 4’de gösterilmiştir. Kelime bulutu, kullanıcıların en sık hangi kavramlara değindiğini görsel olarak özetler. Şekilde “ürün”, “telefon”, “kalite”, “kargo”, “güzel”,




Fig. 3. Yorum uzunluğu dağılımı.



Fig. 4. Ham veri üzerinden oluşturulan WordCloud. En büyük kelimeler en sık geçen terimleri temsil eder.

“memnun” gibi kelimelerin öne çıktığı, hem ürün boyutlarına hem de duygu ifadelerine ait terimlerin sıklıkla tekrarlandığı görülmektedir.

V. VERİ ÖN İŞLEME VE ETİKETLEME

A. Etiketleme Stratejisi

Kazınan ham veride bulunan ve sözlük tabanlı üretilmiş olan mevcut “sentiment” sütununun güvenilir olmadığı tespit edilmiştir. Bu nedenle modelleme için boyut düzeyinde elle/yapay zekâ destekli yeniden etiketleme yapılmıştır. Her yorum, içerdiği her boyut için ayrı bir (yorum, aspect, sentiment) satırına dönüştürülmüş ve duygu etiketi pozitif/negatif/nötr olarak üçlü şemaya oturtulmuştur.

B. Metin Temizleme

Özellikle kural tabanlı ve TF-IDF yöntemleri için altı aşamalı bir metin temizleme hattı uygulanmıştır. Bu pipeline, Python’un regex modülü ile düzenli ifadeler kullanılarak geliştirilmiştir. Adımlar ve gerçek yorum örnekleri Tablo III’te verilmiştir.

Önemli bir tasarım kararı olarak, noktalama işaretlerinden özellikle nokta ve virgül, temizleme sırasında korunmuştur. Bunun nedeni, kural tabanlı sistemde cümle bölme işleminin bu işaretlere dayanmasıdır.

TABLE III
METİN ÖN İŞLEME ADIMLARI

Adım	Açıklama
1. Türkçe küçük harf	İ→i, I→ı özel dönüşümü ile küçük harfe çevirme
2. URL temizleme	http/https/www bağlantılarının kaldırılması
3. Emoji kaldırma	Unicode emoji ve sembollerin silinmesi
4. Tekrarlı karakter	3+ ardışık aynı karakterin 2’ye indirilmesi
5. Özel karakter	Harf, rakam ve temel noktalama dışının temizlenmesi
6. Fazla boşluk	Ardışık boşlukların tek boşluğa düşürülmesi

TABLE IV
YORUM BAZLI TRAIN/VAL/TEST BÖLMESİ

Küme	Örnek	Oran (%)
Eğitim	2.342	~70
Doğrulama	506	~15
Test	510	~15

Transformer modellerinde ise subword tokenizasyonu kullanıldığından metin büyük ölçüde ham bırakılmış, yalnızca “{yorum} [SEP] {aspect}” yardımcı cümle formatına dönüştürülmüştür.

C. Veri Sızıntısının Önlenmesi

ABSA’nın tablo biçiminde özel bir tuzağı vardır. Tek bir yorum birden fazla satır ürettiğinden, satır düzeyinde rastgele bölme yapıldığında aynı yorumun farklı boyut satırları hem eğitim hem test kümesine düşebilir ve veri sızıntısı oluşur. Bu durum başarı ölçütlerini yapay olarak şişirir. Sorunu gidermek için bölme işlemi yorum metni üzerinden gruplandırılarak GroupShuffleSplit ile yapılmış, böylece aynı yorumun tüm satırları yalnızca tek bir kümeye gönderilmiştir. Sabit seed değeri ile elde edilen bölme sonrasında test–eğitim yorum örtüşmesinin %0 olduğu doğrulanmıştır. Bölme oranları Tablo IV’te verilmiştir.

VI. MODELLEME VE YÖNTEMLER

Aynı veri seti üzerinde, başarı–maliyet–yorumlanabilirlik dengesini görmek amacıyla artan karmaşıklıkta dört yaklaşım uygulanmıştır.

A. Yöntem 1 — Kural Tabanlı Sözlük Yaklaşımı

İlk yöntem tamamen kural tabanlıdır ve üç aşamadan oluşur: cümle bölme, boyut tespiti ve duygu sınıflandırması.

Cümle Bölme; Ham yorum, noktalama işaretleri ve karşıtlık bağlaçları üzerinden alt cümleciklere ayrılır. Bu sayede “Kargo hızlıydı ama ürün kalitesiz” gibi bir yorum iki bağımsız parça olarak işlenir ve her parça farklı bir boyuta atanabilir.

Aspect Tespiti; Her alt cümlecik, yedi boyut için hazırlanmış anahtar kelime sözlükleri ile taranır. Sözlükteki kelimelerden herhangi biri cümlede geçiyorsa ilgili boyut o cümleye atanır. Sözlük yapısı Tablo V’te özetlenmiştir.

Duygu Sınıflandırması; Boyutu tespit edilen her cümlecik, pozitif ve negatif kelime sözlükleri ile taranır. Bulunan pozitif

TABLE V
BOYUT SÖZLÜKLERİNDEN ÖRNEK ANAHTAR KELİMELER

Boyut	Anahtar Kelimeler
kargo	kargo, teslimat, kurye, hızlı geldi, geç geldi, teslim...
batarya	batarya, pil, şarj, mAh, ısınma, şarj süresi...
fiyat	fiyat, pahalı, ucuz, eder, performans, indirim, kampa- nya...
kalite	kalite, dayanıklı, sağlam, plastik, malzeme, orijinal, kusur...
ses_goruntu	ses, kamera, ekran, görüntü, hoparlör, çözünürlük, pik- sel...
ambalaj genel	ambalaj, paket, kutu, ezilmiş, hasar, koruma, poşet... ürün, tavsiye, memnun, güzel, kötü, beğendim, öner- irim...

ve negatif kelime sayıları bir skor farkı oluşturur. Olumsuzlama yönetimi kritik bir bileşendir: “değil”, “yok”, “olmaz”, “-me/-ma” gibi olumsuzlama kalıpları yakalandığında, takip eden duygu kelimesinin kutbu tersine çevrilir. Örneğin “kargo hızlı değil” cümlesinde “hızlı” kelimesi normalde pozitif skorlanırken olumsuzlama sonrası negatif olarak sayılır. Skor farkı sıfırda nötr, pozitifse pozitif, negatifse negatif etiket atanır.

Bu yöntem tamamen şeffaf, hızlı ve eğitim verisi gerektirmez. Ancak kelime dağarcığı dışındaki ifadeleri ve örtük duyguları yakalayamaz.

B. Yöntem 1.5 — TF-IDF Hibrit Yaklaşım

İkinci yöntem hibrittir: boyut tespiti yine Yöntem 1 ile aynı kural tabanlı sözlük sistemiyle yapılır, ancak duygu sınıflandırması geleneksel makine öğrenmesi ile gerçekleştirilir. Veri Hazırlama; Etiketli veri setindeki her satır, önce Yöntem 1’deki ön işleme hattından geçirilir, ardından cümlelere bölünür. İlgili boyutu barındıran cümle tespit edilerek “[aspect] cümle” formatında birleştirilir. Eğer boyut kelimesi hiçbir cümlede bulunamazsa, fallback olarak yorumun tamamı kullanılır. “Yok” sınıfı eğitim verisinden çıkarılmıştır; model yalnızca pozitif, negatif ve nötr sınıfları öğrenir. Öznitelik Çıkarımı; Hazırlanan girdiler TF-IDF vektörleştiricisine verilir. Vektörleştirici, unigram ve bigram kullanarak en fazla 5.000 öznitelik çıkarır. Bu yaklaşım, modelin “değil güzel” veya “çok kötü” gibi ikili kalıpları öğrenmesine olanak tanır. Model Seçimi ve Eğitim; Elde edilen TF-IDF vektörleri üzerinde iki aday sınıflandırıcı eğitilmiştir: Lojistik Regresyon max_iter=1000 ve Linear SVM dual=False. Her iki modelde de sınıf dengesizliğini telafi etmek için class_weight=’balanced’ parametresi uygulanmıştır. Model seçimi, 5 katlı Stratified K-Fold çapraz doğrulama ile makro F1 skoruna göre yapılmıştır (random_state=42). Çapraz doğrulama sonuçlarına göre en yüksek makro F1 ortalamasını veren model olan Lojistik Regresyon modeli seçilerek tüm eğitim verisi üzerinde yeniden eğitilmiştir. Eğitilen model ve vektörleştirici joblib ile diske kaydedilerek yeniden kullanılabilir hâle getirilmiştir. Hibrit Avantaj. Böylece model, sabit bir sözlük yerine veriden bağlam öğrenir. Özellikle negatif (+0.11 F1) ve nötr (+0.09 F1) sınıflarında belirgin iyileşme sağlanmıştır. Bununla birlikte, TF-IDF kelime sırası bilgisi taşımadığından uzun bağımlılıkları modelleyemez.

TABLE VI
TRANSFORMER MODELLERİ İÇİN ORTAK EĞİTİM AYARLARI

Hiperparametre	Değer
Girdi formatı	{yorum} [SEP] {aspect}
Maks. uzunluk	128 token
Optimizasyon	AdamW
Öğrenme oranı	2e-5
Ağırlık sönümü	0.01
Isınma oranı	0.1
Parti boyutu	16
Epok / durdurma	maks. 10, patience=2
Kayıp fonksiyonu	ağırlıklı CrossEntropy
Hassasiyet / tohum	fp16 / 42

C. Yöntem 2 — BERTürk İnce Ayar

Üçüncü yöntemde, dbmdz/bert-base-turkish-uncased BERTürk modeli ABSA görevi için ince ayardan geçirilmiştir. Girdi, Sun ve ark. [3] yaklaşımıyla “[yorum] [SEP] {aspect}” yardımcı cümle formatında kurulmuş, maksimum uzunluk 128 token alınmıştır. Eğitim AdamW optimizasyonu (öğrenme oranı 2e-5, ağırlık sönümü 0.01, ısınma oranı 0.1), 16’lık parti boyutu, en fazla 10 epoch ve makro F1 üzerinden erken durdurma ile yürütülmüştür. Nötr sınıfının az temsil edilmesi nedeniyle, kayıp fonksiyonu olarak sınıf ağırlıklı CrossEntropy kullanılmıştır. Eğitim Google Colab T4 GPU üzerinde fp16 ile gerçekleştirilmiş, en iyi sonuç 2. epochta elde edilmiş ve model 4. epochta erken durmuştur.

D. Yöntem 3 — KOZMOS (YTÜ) İnce Ayar

Dördüncü yöntemde, Yıldız Teknik Üniversitesi tarafından geliştirilen ytu-ce-cosmos/turkish-small-bert-uncased (KOZMOS) modeli, BERTürk ile aynı yardımcı cümle formatı, aynı hiperparametreler ve aynı dengeli ağırlıklandırma + erken durdurma stratejisiyle eğitilmiştir. Daha küçük bir model olması, başarı ve maliyet karşılaştırması için anlamlı bir referans sağlar.

E. Deney Ortamı ve Tekrarlanabilirlik

Her iki transformer modeli de Hugging Face Transformers ve PyTorch ile, Google Colab T4 GPU üzerinde eğitilmiştir. Tekrarlanabilirliği güvence altına almak için tüm rastgelelik kaynakları seed=42 ile sabitlemiştir. Aynı bölme, aynı tokenizasyon ve aynı eğitim ayarları iki model için ortak tutularak karşılaştırmanın adil olması sağlanmıştır. Ortak hiperparametreler Tablo VI’te özetlenmiştir.

VII. DENEYSEL SONUÇLAR VE DEĞERLENDİRME

A. Değerlendirme Ölçütleri ve Baseline

Sınıf dağılımı dengesiz olduğundan birincil ölçüt olarak makro F1 seçilmiştir. Accuracy ikincil ve yanıltıcı olabilen bir ölçüt olarak raporlanmıştır. İki temel çizgi belirlenmiştir: her örneği çoğunluk sınıfı (“pozitif”) tahmin eden basit kestirim %59.8 doğruluk verir, TF-IDF + Lojistik Regresyon temel çizgisi ise %78.0 doğruluk ve 0.643 makro F1 ulaşır. Transformer modelleri klasik yöntemlere göre bu çizgilerin beklenen şekilde üzerine çıkmıştır.

TABLE VII
YÖNTEMLERİN TEST KÜMESİ KARŞILAŞTIRMASI (BİRİNCİL ÖLÇÜT: MAKRO F1)

Ölçüt	Y1	Y1.5	BERTürk	KOZMOS
Makro F1	0.51	0.57	0.69	0.657
Pozitif F1	0.68	0.65	0.89	0.88
Negatif F1	0.51	0.62	0.80	0.77
Nötr F1	0.34	0.43	0.38	0.32
Doğruluk	%48.81	%52.18	%81.4	%80.6




Fig. 5. Yöntem 1 (Kural Tabanlı) karmaşıklik matrisi.

B. Karşılaştırmalı Başarı

Dört yöntemin test kümesindeki başarısı Tablo VII’te özetlenmiştir. En yüksek makro F1 (0.69) ve doğruluk (%81.4) değerleri BERTürk modeline aittir. KOZMOS, 0.657 makro F1 ile çok yakın bir ikinci olmuştur.

* Yöntem 1 ve 1.5’te boyut tespiti de kurallarla yapıldığından bu hatlar bazı boyutları hiç yakalayamaz. Karşılaştırma makro F1 üzerinden yapılmalıdır.

Sözlükten transformer’a doğru ilerledikçe en büyük kazanç negatif sınıfta görülmüştür: negatif F1, kural tabanlı 0.51’den BERTürk’te 0.80’e yükselmiştir. Bunun nedeni, olumsuz yorumların çoğunlukla bağlama ve örtük ifadelerle dayanması, sabit bir sözlüğün ise bunları kaçırmasıdır. Dikkat çekici bir bulgu, kısıtlı kapasitesine rağmen Yöntem 1.5’in nötr sınıfta (0.43) tüm derin öğrenme modellerini geçmesidir. Transformer modelleri nötrü temkinli tahmin edip çoğunu kaçırma eğilimindedir.

C. Karmaşıklik Matrisleri

Şekil 5–8, dört yöntemin karmaşıklik matrislerini göstermektedir. Saf kural tabanlı yöntemde (Şekil 5) pozitif sınıf dışındaki tahminlerin oldukça dağınık olduğu görülmektedir. Hibrit modelde (Şekil 6) pozitif/negatif ayrımı belirgin biçimde iyileşmiştir. BERTürk (Şekil 7) ve KOZMOS (Şekil 8) matrislerinde kutuplu sınıflar arası karışım düşüktür. Tüm modellerde hataların ezici çoğunluğu nötr örneklerin kutuplu sınıflara kaymasından kaynaklanır.

D. Tahmin Edilen Boyut Frekansları ve Duygu Dağılımları

Yöntem 1 tarafından üretilen tahminlerdeki boyut frekansları Şekil 9’de, boyut başına tahmin edilen duygu




Fig. 6. Yöntem 1.5 (TF-IDF Hibrit) karmaşıklik matrisi.




Fig. 7. BERTürk karmaşıklik matrisi.




Fig. 8. KOZMOS karmaşıklik matrisi.

dağılımı ise Şekil 10’de gösterilmiştir. Bu grafikler, kural tabanlı sistemin boyut tespit etme başarısını ve her boyuttaki duygu eğilimini görsel olarak ortaya koymaktadır. “Genel” boyutunun açık ara en sık tespit edilen boyut olduğu, bunu kargo ve kalitenin takip ettiği görülmektedir.




Fig. 9. Yöntem 1 tahminlerinde aspect frekans dağılımı.




Fig. 10. Yöntem 1 tahminlerinde aspect başına duygu dağılımı.




Fig. 11. BERTürk için boyut bazlı doğruluk.




Fig. 12. KOZMOS için boyut bazlı doğruluk.

E. Boyut Bazlı Başarı

BERTürk ve KOZMOS modellerinin başarısının boyutlara göre değişimi Şekil 11 ve 12’de verilmiştir. Tek kutuplu ve net ifadelerin yoğunlaştığı boyutlar BERTürk modeli için KOZMOS modeliyle karşılaştırıldığında KOZMOS modelinin bazı niteliklerde öne çıktığı BERTürk modelinin de aynı şekilde bazı niteliklerde daha doğru yüksek sonuçlarla öne çıktığı görülmüştür. Nötr ve karşıt-kutuplu ifadelerin sık görüldüğü boyutlar ise fiyat batarya gibi boyutlarda görece daha zordur. Boyut başına örnek sayıları küçük olduğundan bu oranlar kesin başarı değil eğilim olarak okunmalıdır.

F. Hata Analizi

Karmaşıklık matrisleri, hataların nereden geldiğini somutlaştırır. KOZMOS modelinde nötr sınıfının 45 örneğinden yalnızca 11’i doğru bilinmiştir. 14’ü pozitif, 20’si negatif olarak sınıflandırılmıştır. Buna karşılık kutuplu sınıflar arası karışım düşük ve simetrik. Pozitiflerin yalnızca küçük bir bölümü negatif, negatiflerin küçük bir bölümü pozitif olarak karışmıştır. BERTürk’te nötr geri çağırması daha yüksektir (%40) ve hatalar yine ağırlıklı olarak nötr-kutup ekseninde toplanır. Bu örüntü, modellerin asıl güçlüğünün “olumlu mu olumsuz mu” ayrımı değil, “kararsız/ölçülü ifade” ile zayıf kutuplu ifadeyi birbirinden ayırmak olduğunu göstermektedir. Pratikte bu, nötr örneklerin etiketlenmesindeki öznelliğin doğrudan bir yansımasıdır.

G. Yorumlanabilirlik

Transformer modellerinin kara kutu davranışını anlamak için Captum kütüphanesi ile attention görselleştirilmesi ve katman bazlı integral gradyanları (Layer Integrated Gradients) hesaplanmıştır. Bu analizler, modelin tahmin yaparken çoğunlukla boyutla ilişkili anahtar kelimelere ve olumsuzlama eklerine yüksek katkı atadığını, yani dilbilgisel olarak anlamlı kelimelere odaklandığını göstermiştir.

VIII. TARTIŞMA: GÜÇLÜ VE ZAYIF YÖNLER

Bulgular, problem türü ile yöntem seçimi arasında net bir denge ortaya koymaktadır:

- Kural tabanlı yöntem hızlı, şeffaf ve eğitim verisi gerektirmez ancak kelime dağarcığına bağımlıdır ve örtük/bağlamsal duyguda zayıftır.
- TF-IDF hibrit yöntem, düşük hesaplama maliyetiyle kayda değer iyileşme sağlar ve şaşırtıcı biçimde nötr sınıfta en iyisidir fakat kelime sırasını ve uzun bağlamı modelleyemez.
- Transformer modelleri pozitif/negatif ayrımında açık ara üstündür, nedeni ise GPU gereksinimi ve daha düşük yorumlanabilirliktir.

Tüm modeller için ortak ve temel kısıt nötr sınıfıdır. Bunun iki nedeni vardır: (i) nötr örneklerin sayıca

azlığı (test kümesinde yalnızca 45 örnek) ve (ii) nötr'ün etiketlemede öznel olması. Bir cümlemin nötr mü yoksa hafif olumlu/olumsuz mu olduğu çoğu zaman tartışmalıdır. Sınıf ağırlıklandırması geri çağırma bir miktar iyileştirse de bu sorunu tek başına çözmemiştir. Başka bir problem olarak zaman yorumların insan konuşma diliyle çok farklı bir biçimde yazıldığı için modeller bazı kelimeler arasında tam anlamıyla ilişki kuramamıştır. Bazı yorumların hangi sınıfa ait olması gerektiğiyle ilgili sorun yaşamaktadırlar.

IX. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada Türkçe e-ticaret yorumları için uçtan uca bir konu bazlı duygu analizi sistemi geliştirilmiş ve dört yöntem aynı, sızıntısız veri seti üzerinde karşılaştırılmıştır. BERTürk modeli 0.69 makro F1 ve %81.4 doğruluk ile en yüksek başarıyı elde etmiş, KOZMOS yakın bir performans göstermiştir. Klasik yöntemler ise düşük maliyet ve yüksek şeffaflık avantajlarını korumuştur. Çalışmanın en önemli metodolojik katkısı, ABSA'ya özgü veri sızıntısının yorum bazlı gruplandırma ile tamamen giderilmesi ve böylece gerçekçi başarı ölçütlerinin elde edilmesidir.

Gelecek çalışmalar için öneriler: nötr sınıfını güçlendirmek amacıyla hedefli veri toplama ve veri artırımı; birden çok tohumla (multi-seed) ortalama olarak sonuçların kararlılığının raporlanması; daha büyük Türkçe modellerin (ör. büyük BERTürk veya üretken dil modelleri) denenmesi; boyut tespiti de öğrenen, uçtan uca tek bir model ile birleşik ABSA mimarisinin kurulması.

Çalışmanın başlıca kısıtları şunlardır: veri seti üç elektronik kategorisi ve sınırlı sayıda ürünle sınırlıdır. Bu nedenle sonuçların giyim veya gıda gibi farklı alanlara genellenmesi garanti değildir. Nötr sınıfının az temsil edilmesi ve etiketleme özneliği, bu sınıftaki başarıyı sınırlandırmıştır. Ayrıca sonuçlar tek bir eğitim koşusundan elde edildiğinden, küçük ölçekli varyans henüz nicelenmemiştir.

Pratik açıdan, boyut bazlı duygu çıktıları doğrudan iş değeri taşır. Bir satıcı, ürününe dair şikâyetlerin hangi boyutta yoğunlaştığını otomatik olarak izleyebilir. Platform ise binlerce yorumu boyut bazında özetleyerek tüketiciye yıldız puanının ötesinde ayrıntılı bir görünüm sunabilir.

X. SÜREÇ YÖNETİMİ VE DEPO YAPISI

Çalışma, başından sonuna GitHub üzerinde yürütülmüştür. Depo; README, data/, notebooks/, src/, visuals/ ve docs/ klasörlerinden oluşan standart bir yapıya oturtulmuştur. Üç yöntem ailesi ayrı dallarda (yontem_1, yontem_2/yontem_berturk, yontem_cozmos) geliştirilmiş, olgunlaşan çalışma develop dalında birleştirilmiştir. Her anlamlı aşama (ham verinin yüklenmesi, etiketleme, ön işleme, ilk model sonuçları, karşılaştırmalı deneyler, görsellerin revizyonu) ayrı ve açıklayıcı commit'lerle kayıt altına alınmıştır. Böylece projenin zaman içindeki gelişimi izlenebilir kılınmıştır. Tüm not defterleri ve scriptler yeniden çalıştırılabilir olacak şekilde, veriye GitHub ham bağlantıları üzerinden erişecek biçimde düzenlenmiştir.

XI. YAPAY ZEKÂ ARAÇLARININ KULLANIMI

Yapay zekâ destekli araçlar; (i) boyut düzeyinde etiketlemenin hızlandırılmasında insan kontrolü altında yardımcı olarak, (ii) kod hata ayıklama ve kütüphane uyumluluğu konularında danışma amacıyla kullanılmıştır. Modelleme kararları, hiperparametre seçimleri, veri toplama ve nihai değerlendirme ekip tarafından yürütülmüştür.

REFERENCES

- [1] M. Pontiki, D. Galanis, J. Pavlopoulos, H. Papageorgiou, I. Androulopoulos ve S. Manandhar, "SemEval-2014 Task 4: Aspect Based Sentiment Analysis," *Proc. of the 8th Int. Workshop on Semantic Evaluation (SemEval)*, 2014, ss. 27–35.
- [2] J. Devlin, M.-W. Chang, K. Lee ve K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *Proc. NAACL-HLT*, 2019, ss. 4171–4186.
- [3] C. Sun, L. Huang ve X. Qiu, "Utilizing BERT for Aspect-Based Sentiment Analysis via Constructing Auxiliary Sentence," *Proc. NAACL-HLT*, 2019, ss. 380–385.
- [4] S. Schweter, "BERTurk — BERT models for Turkish," Zenodo, 2020. [Çevrimiçi]. Mevcut: <https://github.com/dbmdz/berts>
- [5] YTU CE COSMOS, "Turkish Small BERT (uncased)," Hugging Face Model Hub. [Çevrimiçi]. Mevcut: <https://huggingface.co/ytu-ce-cosmos>
- [6] T. Wolf ve diğ., "Transformers: State-of-the-Art Natural Language Processing," *Proc. EMNLP: System Demonstrations*, 2020, ss. 38–45.
- [7] F. Pedregosa ve diğ., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, c. 12, ss. 2825–2830, 2011.
- [8] N. Kokhlikyan ve diğ., "Captum: A unified and generic model interpretability library for PyTorch," arXiv:2009.07896, 2020.